

Plan de Arquitectura, Costos y Roadmap 2026

Motor propio de agentes IA para ecommerce LATAM

Cómo usar este documento

Este brief está pensado para subirlo a Claude Cowork (o Claude Code) como contexto inicial. Define qué construimos, con qué stack, a qué costo y en qué orden. Todos los precios y requisitos fueron verificados en mayo 2026; donde algo no está confirmado, está marcado como **A VALIDAR**. Los precios de APIs cambian: reconfirmar antes de comprometer presupuesto.

Resumen ejecutivo

Objetivo: construir un motor propio de agentes de IA para ecommerce — una alternativa enfocada a Convocore, que cubra solo lo que necesitamos y corrija sus puntos débiles. Modelo operativo Account Manager: el cliente nunca toca la plataforma. Presupuesto techo: **USD 1.000 para todo 2026**.

Reality check (sin chamuyo)

- USD 1.000 alcanza para infra + APIs del año a volumen MVP, no para contratar gente.** La mano de obra sos vos + Claude.
- Cowork no hostea ni corre el producto.** Sirve para la capa de negocio/ops/contenido y para asistir con código. El build pesado conviene en Claude Code; la plataforma viva corre en infra aparte.
- Construir todo a la vez es inviable.** 5 canales + 3 marketplaces + voz + constructor de flujos es un producto grande. Entra en el año solo si se faseta con disciplina.
- Voz y constructor de flujos** son lo más caro y complejo: van a fases finales.

1. Arquitectura del sistema

Plataforma multi-tenant (varios clientes en una sola instancia). Flujo central: un mensaje entra por un canal, se enruta al cerebro del agente, que consulta la base de conocimiento (RAG) y los datos del ecommerce, genera la respuesta y la devuelve por el mismo canal. Todo queda registrado para el inbox y las métricas.

Capa	Componente	Función
Ingreso	Conectores de canal	Webhooks de WhatsApp, Instagram, Messenger, Telegram, Gmail. Normalizan todo a un formato único.
Cerebro	Orquestador LLM	Arma el prompt (sistema + RAG + few-shot), elige modelo, controla anti-alucinación y handoff a humano.
Conocimiento	Base RAG (pgvector)	Ingesta de docs y catálogo → chunking → embeddings → búsqueda. top_k 8-10, chunk ~4.000 chars.
Datos comercio	Conectores ecommerce	Tiendanube / Mercado Libre / Shopify: catálogo, stock, estado de pedidos para responder con datos reales.
Persistencia	Postgres	Tenants, conversaciones, mensajes, configuración, métricas. pgvector para los embeddings.
Front	Panel + Inbox	Inbox de chats, seguimiento, handoff, dashboard de métricas. Uso interno (Account Manager).

Flujo: Canal → Webhook → Orquestador → (RAG + datos del comercio) → LLM → respuesta → Canal. En paralelo: cada interacción se guarda para inbox y métricas. Handoff a humano cuando el bot no tiene confianza.

2. Stack técnico recomendado (lean)

Elegido para minimizar costo fijo y tiempo de build, reutilizando lo que ya sabés de Convocore (RAG, prompts, anti-alucinación).

Pieza	Elección recomendada	Por qué / nota
Backend	Node.js + TypeScript (o Python/FastAPI)	Ecosistema fuerte para webhooks y SDKs de Meta. Claude Code lo genera bien.
Base de datos	Postgres + extensión pgvector	Una sola DB para datos y vectores. Evita pagar un vector DB aparte (Pinecone).
Modelo IA bot	Gemini 2.5 Flash o GPT-5 mini	Lo más barato por token a volumen. Escalar a Sonnet solo en casos difíciles.
Hosting	VPS (Hetzner) o Railway/Render	VPS = más barato; Supabase/Railway = más rápido de armar. Ver costos abajo.
Front/Panel	Next.js en Vercel (Hobby)	Plan gratis alcanza para el panel interno al inicio.
Auth/Storage	Supabase (opcional)	Si se usa Supabase, auth + storage + Postgres + pgvector en un solo lugar.

3. Integraciones: canales y marketplaces

3.1 Canales de mensajería

Canal	Cómo se integra	Costo	Estado
WhatsApp	WhatsApp Cloud API (Meta Graph + webhooks)	Soporte dentro de ventana 24h: GRATIS. Templates de marketing: por mensaje, varía por país.	Requiere verificación de negocio Meta
Instagram	Instagram Messaging API (Meta)	Mensajería en ventana de servicio sin cargo de Meta	Mismo Business Manager
Messenger	Messenger Platform (Meta)	Igual que IG	Mismo Business Manager
Telegram	Bot API oficial	GRATIS	El más fácil — ideal para prototipar primero
Gmail/Calendar	Google APIs (OAuth)	GRATIS (cuotas amplias)	Para canal email + agendado de demos
TikTok	Mensajería restringida / por aprobación	—	A VALIDAR: no hay API de DM abierta como Meta

Nota WhatsApp: desde el 1 de julio de 2025 Meta cobra por mensaje (no por conversación). Los mensajes de atención al cliente dentro de la ventana de 24h no se cobran; los leads que llegan por anuncios Click-to-WhatsApp tienen 72h gratis. El costo real aparece recién en templates de marketing salientes.

3.2 Marketplaces / plataformas de ecommerce

Plataforma	Programa / acceso	Costo de entrada	Nota clave
Tiendanube	Portal de Socios + API pública + Tienda de Aplicaciones	Gratis para construir	Revenue share solo en pagos y envíos (no aplica a un bot). Requiere app aprobada y soporte en idioma local.
Mercado Libre	DevCenter (OAuth) + Developer Partner Program	API gratis	No es un 'canal': el bot responde preguntas y post-venta vía API. Partner Program exige certificación + eval de seguridad (65%+).
Shopify	Partner Program + App Store	USD 19 one-time (plan de revenue share)	0% de revenue share sobre el primer USD 1M (de por vida), 15% después. Requiere revisión de la app.

Construir las tres integraciones es gratis o casi. El costo real es el tiempo de desarrollo y los ciclos de aprobación de cada app store (pueden demorar).

4. Costos 2026 (techo USD 1.000)

Dos caminos de infraestructura. Todos los montos son estimados a volumen MVP / bajo tráfico y deben reconfirmarse: los precios de APIs se mueven seguido.

Camino A — Lean (recomendado para arrancar)

Ítem	Costo	Anual aprox.
Dominio	~USD 12/año	USD 12
VPS (Hetzner, Postgres+app en Docker)	~USD 5-6/mes	USD 60-72
Vector DB (pgvector en el mismo Postgres)	USD 0	USD 0
Front (Vercel Hobby)	USD 0	USD 0
Tokens LLM (Gemini Flash / GPT-5 mini)	~USD 10-50/mes	USD 120-600
Shopify Partner (one-time)	USD 19	USD 19
WhatsApp templates marketing (variable)	según envíos	buffer
TOTAL estimado año 1	—	~USD 210-700

Camino B — Managed (más rápido de armar, más caro)

Ítem	Costo	Anual aprox.
Supabase Pro (Postgres+auth+storage+pgvector)	USD 25/mes	USD 300
Railway / Render (backend)	~USD 5-20/mes	USD 60-240
Dominio + Shopify one-time	USD 12 + 19	USD 31
Tokens LLM	~USD 10-50/mes	USD 120-600
TOTAL estimado año 1	—	~USD 511-1.171

Conclusión de presupuesto

El **Camino A entra con holgura** en los USD 1.000 incluso con buffer para templates y picos de tokens. El Camino B también entra si el volumen es MVP, pero deja menos margen. **Voz queda fuera del año 1** como costo recurrente: a ~USD 0.06-0.17/min se activa solo como add-on pago por cliente.

5. Roadmap por fases (2026)

Orden pensado para tener algo demostrable rápido y sumar complejidad sin reventar el presupuesto.

Fase 0 — Setup

- Cuentas y accesos: Meta Business + verificación de negocio (prerequisito de WhatsApp — mismo bloqueo que tocaste en Parlyx).
- Alta en Tiendanube Portal de Socios, Mercado Libre DevCenter y Shopify Partners.
- Repo, entorno de desarrollo y esqueleto del backend (con Claude Code).

Fase 1 — MVP core

- 1 canal primero (Telegram para prototipar rápido y gratis; luego WhatsApp).
- Base de conocimiento + RAG (reutilizar tu know-how de Convocore: top_k 8-10, chunk ~4.000).
- Inbox básico + handoff a humano.
- 1 integración de comercio. Sugerencia: Tiendanube por alcance LATAM; alternativa Shopify por reutilizar lo de Parlyx.

Fase 2 — Expansión

- Sumar Instagram + Messenger + Gmail/Calendar.
- Dashboard de métricas.
- Segunda integración de comercio y primer envío a app store (aprobación lleva tiempo).

Fase 3 — Avanzado

- Constructor de flujos automatizados (empezar simple: triggers + intents, no un editor de nodos completo).
- Voz IA como add-on pago.
- Tercera integración + validar viabilidad de TikTok antes de prometerlo.

6. Cómo usar Cowork (y Claude Code)

Cowork es un agente de escritorio en Claude Desktop (research preview, 2026): lee y escribe archivos en carpetas que le das, corre código y ejecuta tareas multi-paso. No hostea ni corre tu producto en producción. Confirmá que esté habilitado en tu plan Max y tu sistema operativo.

Tarea	Herramienta
Construir y desplegar el código del producto	Claude Code
Generar/editar este tipo de documentos, planes, specs	Cowork
Investigación, análisis de datos, CRM, contenido, ops	Cowork
Mantener el contexto del proyecto (este PDF)	Cowork
Correr/monitorear la plataforma viva	Infra propia (no Claude)

7. Riesgos y supuestos

- **Precios de APIs** cambian seguido (LLM, WhatsApp). Reconfirmar antes de comprometer gasto.
- **Verificación Meta** es prerequisite y puede demorar/bloquear WhatsApp.

- **Aprobación en app stores** tiene barras de calidad y ciclos de revisión; no es inmediata.
- **TikTok**: acceso a mensajería restringido. No comprometer hasta validar.
- **Voz y flujos**: lo más caro/complejo. Diferidos a propósito.
- **Volumen**: las estimaciones asumen tráfico MVP. A escala, los tokens y templates suben — revisar antes de crecer.

8. Próximos pasos inmediatos

- Confirmar Cowork habilitado en Max + decidir Camino A (lean) vs B (managed).
- Lanzar verificación de negocio en Meta (lo que más tarda).
- Crear cuentas de partner en Tiendanube, Mercado Libre y Shopify.
- Con Claude Code: esqueleto del backend + Postgres/pgvector + 1 conector (Telegram) + RAG.
- Definir nombre del producto (working title: 'Parlyx Core', reemplazable).